A distribuição populacional dos municípios cearenses segue a Lei de Zipf?

Davi Passos
Universidade de Fortaleza | Mestrado em Ciência da Computação | Ciência de Dados Aplicada à Ciência das Cidades

Resumo. Este trabalho investiga se a população dos 184 municípios do Ceará segue a Lei de Zipf, com dados do Censo Demográfico 2022. Dois métodos são comparados: a regressão rank-size por mínimos quadrados, comum nos estudos urbanos, e o estimador de máxima verossimilhança recomendado por Newman (2005), com o início da cauda escolhido pelo critério de Kolmogorov-Smirnov. A regressão resulta em q = 0,90 (R^2 = 0,94) para todos os municípios e q = 0,99 para os 20 maiores. A máxima verossimilhança resulta em α = 2,18 ± 0,10 para os 129 municípios com mais de 15 mil habitantes, valor compatível com a Lei de Zipf (α = 2). Mesmo assim, o teste de aderência indica que uma única lei de potência descreve mal essa cauda (p = 0,03), por causa da primazia de Fortaleza, que reúne 27,6% da população estadual, e da escassez de cidades médias. A comparação com outros sete estados (Bahia, São Paulo, Rio de Janeiro, Minas Gerais, Paraná, Santa Catarina e Rio Grande do Sul) mostra que o Ceará é o único em que o expoente é compatível com Zipf, mas a lei de potência é rejeitada, e o que tem a maior falta relativa de cidades médias. Mostra também que a conclusão depende do método: o teste de mínimos quadrados subestima a incerteza e rejeita a lei entre os 20 maiores municípios de quatro estados, enquanto o erro corrigido não a rejeita em nenhum.

Palavras-chave: Lei de Zipf; lei de potência; hierarquia urbana; máxima verossimilhança; Ceará.

1. Introdução: qual é o problema?

Muitas grandezas medidas pelos cientistas têm um tamanho típico, como a altura das pessoas. O tamanho das cidades não tem: num mesmo país convivem metrópoles com milhões de habitantes e vilas com algumas centenas. Newman (2005) mostra que, quando o histograma das populações urbanas é desenhado com os dois eixos em escala logarítmica, os pontos se alinham numa reta. Isso significa que a fração de cidades com população x segue uma lei de potência,

$$p(x) = Cx^{-\alpha}, \tag{1}$$

em que α é o expoente. A regularidade foi notada por Auerbach em 1913 (apud NEWMAN, 2005) e popularizada por Zipf (1949) na forma de ranking: se as cidades são ordenadas da maior para a menor, a população da cidade na posição r é aproximadamente $P_r \propto r^{-q}$, com $q \approx 1$. Pela forma estrita da lei, a segunda cidade teria metade da população da primeira, a terceira um terço, e assim por diante.

As duas formulações descrevem o mesmo fenômeno. Newman (2005, Apêndice A) mostra que o gráfico de posição contra tamanho é a distribuição cumulativa $P(X \geq x)$ desenhada com os eixos trocados. Se a densidade segue a Equação 1, a distribuição cumulativa decai com expoente $\alpha - 1$, e portanto

$$q = \frac{1}{\alpha - 1} \quad \Longleftrightarrow \quad \alpha = 1 + \frac{1}{q}. \tag{2}$$

A Lei de Zipf estrita corresponde a $\alpha = 2$. Para as cidades dos Estados Unidos com mais de 40 mil habitantes, Newman estima α = 2,30, ou seja, $q \approx 0{,}77$.

A explicação mais aceita para essa regularidade é um processo de crescimento proporcional. Simon (1955) propôs que cada novo habitante escolhe uma cidade com probabilidade proporcional ao tamanho dela, o mecanismo que Newman chama de processo de Yule ou princípio de Gibrat. Gabaix (1999) mostrou que, se as cidades crescem a taxas aleatórias que não dependem do tamanho, a distribuição resultante tende a $q = 1$. Desvios da lei, portanto, sinalizam que o crescimento urbano não foi proporcional: algumas cidades cresceram mais do que o seu tamanho permitiria prever. Os testes empíricos mostram que a forma estrita é rejeitada em muitos países e que o resultado depende da definição de cidade e do estimador usado (SOO, 2005).

O Ceará é um caso interessante porque sua rede urbana é dominada por Fortaleza, seguida de longe por Caucaia, Juazeiro do Norte, Maracanaú e Sobral. **O problema investigado é se a distribuição populacional dos municípios cearenses se aproxima da Lei de Zipf e em que medida Fortaleza se diferencia do restante da hierarquia.** A questão importa para o planejamento, porque a concentração da população define a demanda por transporte intermunicipal, hospitais, universidades e saneamento, e a Lei de Zipf

funciona como referência para identificar desequilíbrios na rede urbana. Há também uma questão de método: Newman (2005) alerta que o ajuste de uma reta por mínimos quadrados, o procedimento mais usado, produz estimativas enviesadas do expoente. Por isso, o trabalho compara esse procedimento com o estimador de máxima verossimilhança e repete a análise para outros sete estados do Nordeste, do Sudeste e do Sul, para saber se o padrão cearense é particular.

2. Dados e métodos: o que foi feito?

Dados. Foram usados os dados de população residente do Censo Demográfico 2022, tabela 4709, variável 93, do Sistema IBGE de Recuperação Automática (SIDRA), e a malha municipal do IBGE, ambos obtidos pela API de serviços de dados do instituto. A unidade de análise é o município: 184 no Ceará, 417 na Bahia, 645 em São Paulo, 92 no Rio de Janeiro, 853 em Minas Gerais, 399 no Paraná, 295 em Santa Catarina e 497 no Rio Grande do Sul. Os estados de comparação cobrem redes urbanas diferentes. A Bahia é o estado mais populoso do Nordeste e tem uma capital de porte quase igual ao de Fortaleza; São Paulo e Rio de Janeiro abrigam as duas maiores metrópoles do país; Minas Gerais é o estado com mais municípios; e os três estados do Sul representam redes com vários centros regionais, incluindo Santa Catarina, onde a capital não é o maior município.

Regressão rank-size. Os municípios de cada estado foram ordenados da maior para a menor população, e estimou-se por mínimos quadrados ordinários a reta $\log_{10} P_r = a - q \log_{10} r$. O expoente q é o negativo da inclinação, e o R^2 mede quanto da variação de $\log_{10} P_r$ a reta descreve. O ajuste foi feito com todos os municípios e com os 20 maiores, faixa em que a lei costuma ser mais plausível. A hipótese $q = 1$ foi testada de duas formas: com o erro padrão usual da regressão e com o erro assintótico $q\sqrt{2/n}$ de Gabaix e Ibragimov (2011). O segundo é necessário porque os pontos de um gráfico de ranking não são independentes, já que a posição de cada cidade depende de todas as maiores do que ela, e o erro usual da regressão fica pequeno demais.

Máxima verossimilhança. Seguindo Newman (2005, Eq. 5 e 6), o expoente da Equação 1 foi estimado por

$$\hat{\alpha} = 1 + n \left[\sum_{i=1}^{n} \ln \frac{x_i}{x_{\min}} \right]^{-1}, \qquad \sigma = \frac{\hat{\alpha} - 1}{\sqrt{n}}, \tag{3}$$

em que x_i são as populações dos n municípios com pelo menos $x_{\min}$ habitantes. O limite $x_{\min}$ é necessário porque poucas distribuições reais seguem a lei de potência em toda a faixa; ela costuma valer só na cauda superior. Para escolhê-lo sem arbitrariedade, usou-se o critério de Clauset, Shalizi e Newman (2009): cada população observada foi testada como candidata a $x_{\min}$ (com pelo menos 10 municípios na cauda), e escolheu-se a que minimiza a distância de Kolmogorov-Smirnov D entre a distribuição empírica e a ajustada. A aderência foi avaliada por bootstrap paramétrico com 1.000 amostras sintéticas: o p é a fração de amostras, geradas a partir do modelo ajustado, com D maior ou igual ao observado. Pelo critério dos autores, $p < 0{,}1$ indica que a lei de potência não é plausível. A hipótese $\alpha = 2$ foi testada com o erro σ da Equação 3.

Medidas de concentração. Foram calculados a participação do maior município na população estadual, a razão entre o primeiro e o segundo municípios, o coeficiente de Gini das populações municipais e a parcela da população que vive nos 10% maiores municípios, medida que Newman (2005) estima em cerca de 60% para os Estados Unidos.

Todo o processamento foi feito em Python (pandas, NumPy, SciPy e Matplotlib), num notebook que baixa os dados do IBGE e reproduz todas as tabelas e figuras deste texto.

3. Resultados e discussão: o que foi encontrado?

3.1. A hierarquia urbana do Ceará

Em 2022, Fortaleza tinha 2.428.708 habitantes, 27,6% da população do estado e 6,83 vezes a de Caucaia, o segundo município (355.679). Os 19 maiores municípios, 10% do total, reúnem 54,1% da população, e o Gini das populações municipais é 0,617. O mapa da Figura 1(a) mostra a concentração na Região Metropolitana de Fortaleza e os polos secundários no norte (Sobral) e no sul (Juazeiro do Norte e Crato).

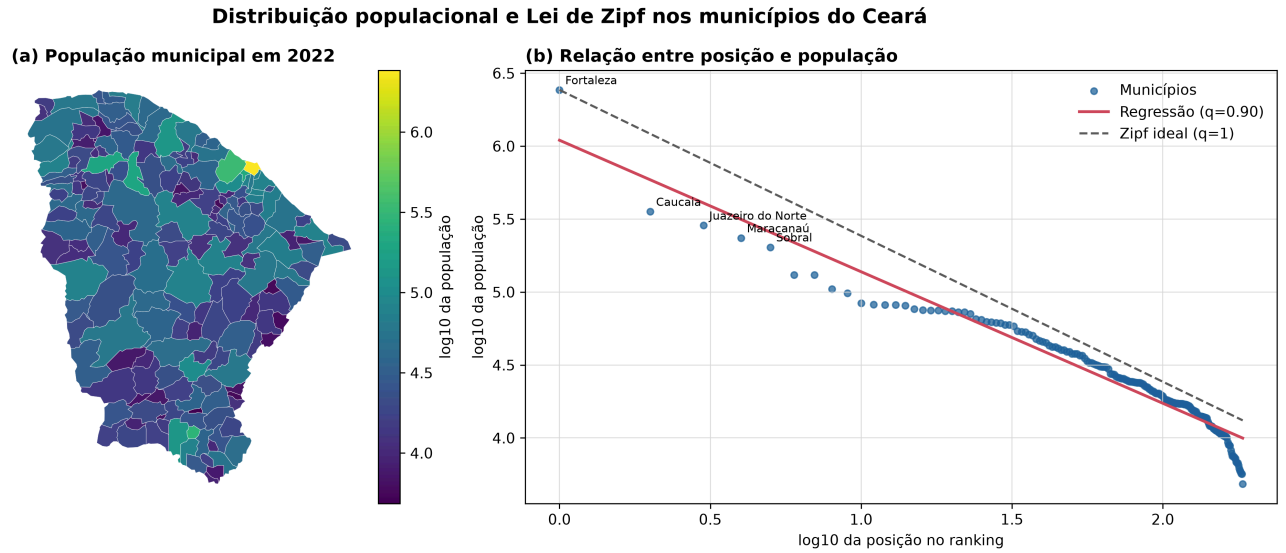


Figura 1: (a) População dos municípios do Ceará em 2022, em escala logarítmica; (b) gráfico rank-size com a reta de mínimos quadrados e a Lei de Zipf estrita ancorada em Fortaleza. Fonte: elaboração própria com dados do IBGE.

A regressão rank-size com os 184 municípios resulta em q = 0,901 e R^2 = 0,940 (Figura 1(b)). Pelo erro padrão usual, o intervalo de 95% de q vai de 0,868 a 0,935 e rejeita a Lei de Zipf ($p < 0,001$). Com o erro de Gabaix e Ibragimov (0,094), porém, o intervalo vai de 0,72 a 1,09 e inclui 1 (p = 0,29). Entre os 20 maiores, q = 0,988 e R^2 = 0,891, compatível com a lei pelos dois critérios (p = 0,887 e p = 0,970). O R^2 alto mostra que a relação é bem descrita por uma reta, mas não diz se a inclinação é igual a −1 nem se a distribuição é de fato uma lei de potência (CLAUSET; SHALIZI; NEWMAN, 2009). A reta ajustada aos 184 municípios prevê 1,10 milhão de habitantes para a primeira posição, menos da metade da população real de Fortaleza.

A máxima verossimilhança escolhe $x_{\min}$ = 15.157 habitantes, de modo que a cauda reúne 129 municípios, 70% do total. O expoente estimado é α = 2,18 ± 0,10 (intervalo de 95% de 1,97 a 2,38), o que equivale a q = 0,85 pela Equação 2. O valor de Zipf, $\alpha = 2$, fica dentro do intervalo (p = 0,089). O teste de aderência, porém, resulta em p = 0,033, abaixo do limite de 0,1: uma única lei de potência não descreve bem a cauda cearense. A Figura 2(a) mostra por quê. A curva acompanha a reta até cerca de 60 mil habitantes, mas cai abaixo dela entre 70 mil e 400 mil, e Fortaleza fica muito acima. A lei ajustada prevê 14 municípios com mais de 100 mil habitantes, e o Ceará tem apenas 8. A rede cearense combina, portanto, uma capital grande demais com poucas cidades médias.

3.2. Comparação com outros estados

A Tabela 1 e a Figura 3 resumem a concentração nos oito estados. Na participação da maior cidade, o Ceará (27,6%) só fica atrás do Rio de Janeiro (38,7%); na razão entre o primeiro e o segundo municípios, só São Paulo (8,87) e Rio de Janeiro (6,93) superam Fortaleza (6,83). Na Figura 3(a), as curvas desses três estados são as que mais caem da primeira para a segunda posição. Salvador tem praticamente a mesma população de Fortaleza, mas reúne 17,1% da população baiana e é 3,92 vezes maior que Feira de Santana. No extremo oposto, Santa Catarina é o estado mais policêntrico: Joinville, o maior município, é só 1,15 vez maior que a capital, Florianópolis. O Gini conta outra história, porque mede a desigualdade entre todos os municípios. O Ceará (0,617) tem o segundo menor valor, atrás só da Bahia (0,584), porque quase não tem municípios muito pequenos: só 1 tem menos de 5 mil habitantes, enquanto em São Paulo, Minas Gerais e nos três estados do Sul essa faixa reúne entre 23% e 48% dos municípios.

A Tabela 2 mostra que a conclusão sobre a Lei de Zipf depende do método. Com todos os municípios, o q da regressão varia de 0,83 (Bahia) a 1,42 (Rio de Janeiro), porque é dominado pela parte de baixo da distribuição, que não segue lei de potência (os pontos cinza da Figura 2). Pelo erro usual, a regressão rejeita $q = 1$ nos oito estados; com o erro de Gabaix e Ibragimov, deixa de rejeitar no Ceará, em Minas Gerais e no Paraná. Entre os 20 maiores, a diferença é ainda maior: o erro usual rejeita a lei em Minas Gerais, no Paraná, em Santa Catarina e no Rio Grande do Sul ($p < 0,001$), e o erro corrigido não a rejeita em nenhum estado (p entre 0,28 e 0,97). Com só 20 pontos, o intervalo de q tem cerca de ±0,5 a ±0,6, e o teste quase não tem poder

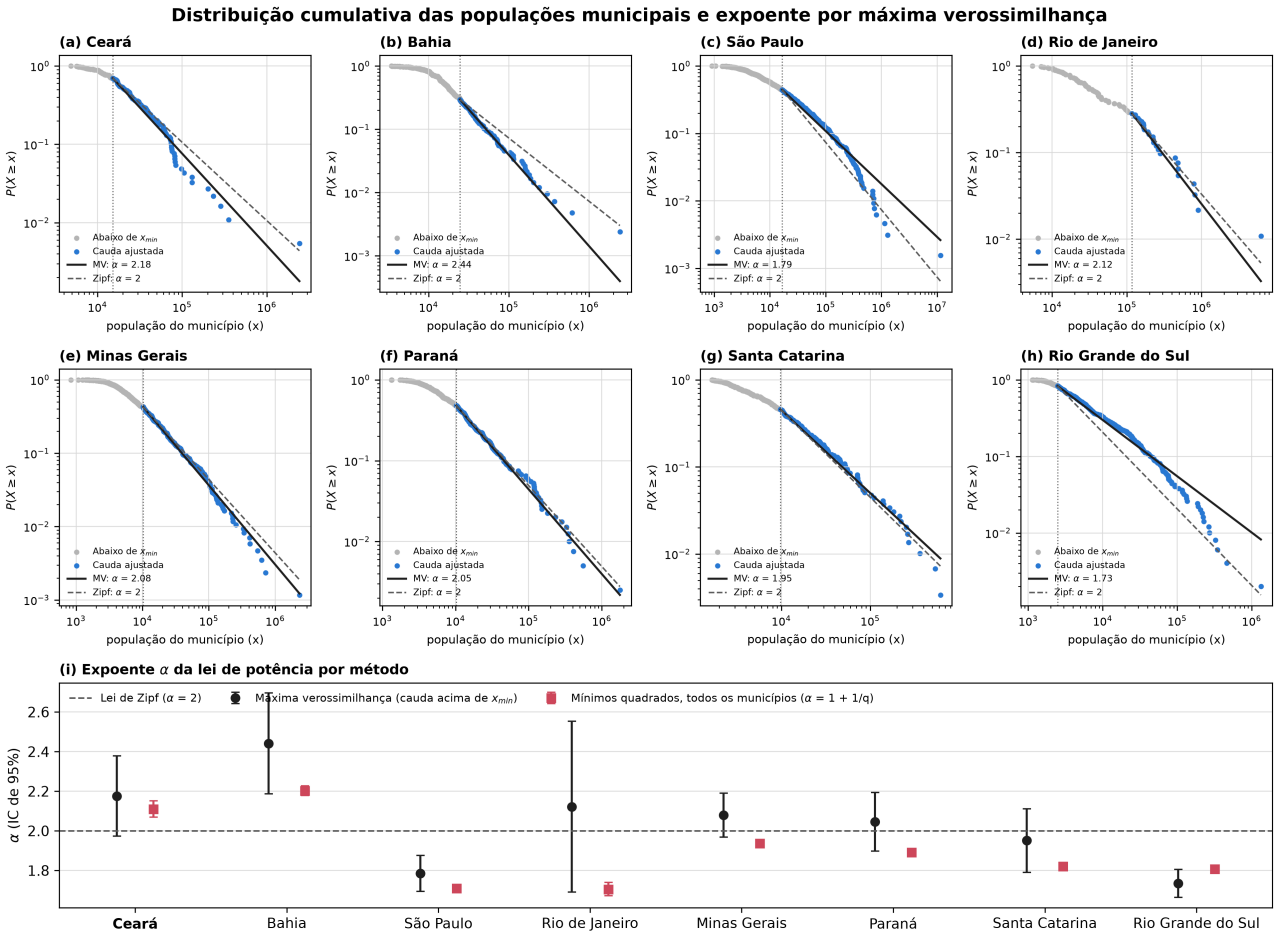


Figura 2: (a)–(h) Distribuição cumulativa complementar $P(X \geq x)$ das populações municipais em 2022. Os pontos cinza ficam abaixo de $x_{\min}$; a linha cheia é a lei de potência estimada por máxima verossimilhança e a tracejada é a Lei de Zipf ($\alpha = 2$) com o mesmo ponto de partida. (i) Expoente α com intervalo de 95% pelos dois métodos; para os mínimos quadrados, $\alpha = 1 + 1/q$ com o intervalo da regressão. Fonte: elaboração própria com dados do IBGE.

para distinguir estados. Os intervalos estreitos da Figura 3(b) e dos mínimos quadrados na Figura 2(i) são, portanto, enganosos, e as estimativas dos dois métodos chegam a diferir em 0,42 (Rio de Janeiro).

Pela máxima verossimilhança, a lei de potência é plausível (p de aderência ≥ 0,1) em cinco estados: Bahia, Rio de Janeiro, Minas Gerais, Paraná e Santa Catarina. Nos quatro últimos, o expoente é compatível com a Lei de Zipf (α entre 1,95 e 2,12); na Bahia, é mais íngreme (α = 2,44, q = 0,69), ou seja, a população se distribui mais entre cidades médias. Em São Paulo e no Rio Grande do Sul, a lei de potência é rejeitada e o expoente fica abaixo de 2 (α = 1,79 e 1,73). Nos dois, as curvas da Figura 2(c) e (h) são côncavas e caem mais rápido que a reta acima de 100 mil habitantes, ou seja, há menos cidades grandes do que o modelo prevê. O resultado do Rio de Janeiro deve ser lido com cautela: a cauda tem só 26 municípios e o intervalo de α vai de 1,69 a 2,55, de modo que o teste tem pouco poder para rejeitar a lei.

Tabela 1: Medidas de concentração populacional nos oito estados em 2022.

Estado	Municípios	Participação da maior cidade	Razão 1ª/2ª	Gini	População nos 10% maiores
Ceará	**184**	**27,6%**	**6,83**	**0,617**	**54,1%**
Bahia	417	17,1%	3,92	0,584	52,7%
São Paulo	645	25,8%	8,87	0,802	72,2%
Rio de Janeiro	92	38,7%	6,93	0,769	69,3%
Minas Gerais	853	11,3%	3,25	0,693	62,3%
Paraná	399	15,5%	3,19	0,709	64,3%
Santa Catarina	295	8,1%	1,15	0,703	61,5%
Rio Grande do Sul	497	12,2%	2,88	0,740	65,5%

Fonte: elaboração própria com dados do IBGE.

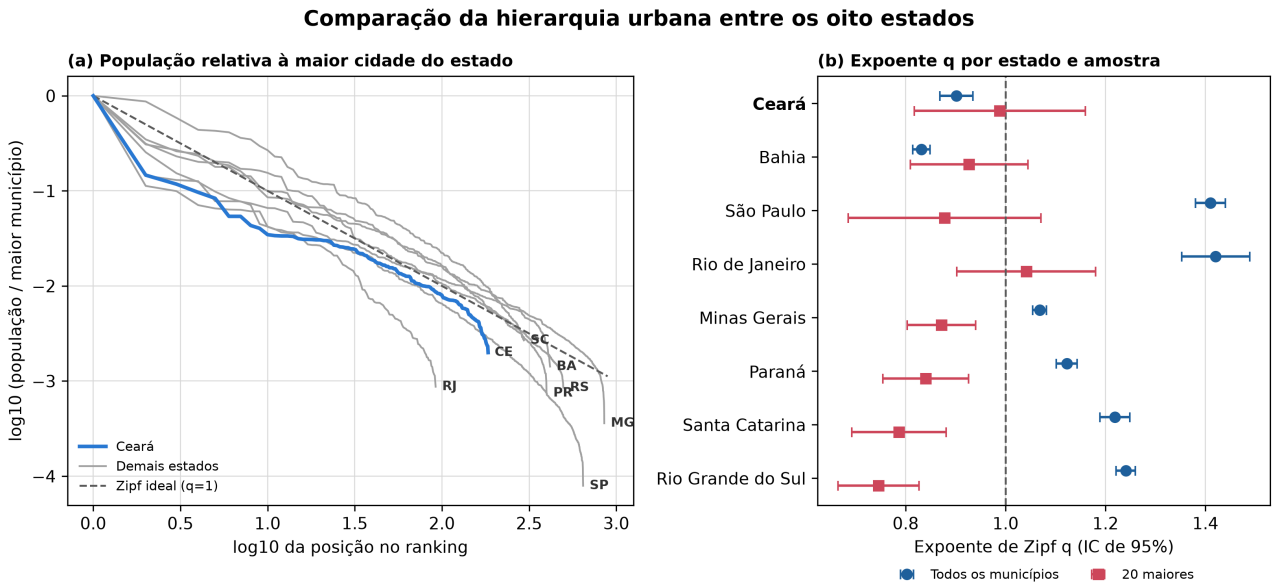


Figura 3: (a) População de cada município relativa à maior cidade do estado, por posição no ranking, em escala log-log; o Ceará aparece em destaque e a linha tracejada é a Lei de Zipf estrita. (b) Expoente q da regressão com o intervalo de 95% do erro padrão usual, para todos os municípios e para os 20 maiores. Fonte: elaboração própria com dados do IBGE.

O Ceará é o único dos oito estados em que o expoente é compatível com 2, mas a lei de potência é rejeitada. Também é o estado com a maior falta relativa de cidades médias: a lei ajustada prevê 14 municípios com mais de 100 mil habitantes e há 8, ou 57% do previsto. No Rio Grande do Sul, a proporção é de 69% (19 de 27,4), e nos outros seis estados fica entre 90% e 124%.

3.3. Interpretação

Os resultados respondem à pergunta inicial em duas partes. No conjunto, a hierarquia cearense tem a inclinação da Lei de Zipf: os dois métodos dão q entre 0,85 e 0,99, com intervalos que incluem 1 quando a incerteza é calculada corretamente. A forma da distribuição, porém, não é a de uma lei de potência, porque Fortaleza é grande demais e faltam cidades entre 100 mil e 400 mil habitantes. Se o crescimento fosse proporcional ao tamanho, como no mecanismo de Simon (1955) e Gabaix (1999), seria de esperar uma cauda contínua e mais municípios médios. O desvio é coerente com uma história de crescimento concentrado na capital, mas este trabalho não testa essa explicação. A comparação mostra que a primazia de Fortaleza é alta, comparável à do Rio de Janeiro e à de São Paulo, mas que a combinação de primazia com falta de cidades médias é particular do Ceará. A Bahia, com uma capital do mesmo porte, tem mais que o dobro de municípios acima de 100 mil habitantes, e no Rio de Janeiro, de primazia parecida, o número de municípios acima desse limite fica próximo do previsto (28 contra 31). Para o planejamento, isso reforça a importância de fortalecer os polos regionais (Juazeiro do Norte, Crato, Sobral e Iguatu) ao lado das ações metropolitanas.

Tabela 2: Expoentes de Zipf por mínimos quadrados e por máxima verossimilhança nos oito estados.

Estado	Mínimos quadrados				Máxima verossimilhança				
	q todos	p GI	q 20 maiores	p usual	p GI	$\alpha \pm$ erro	p de $\alpha = 2$	p de aderência	≥ 100 mil prev./obs.
Ceará	**0,90**	**0,295**	**0,99**	**0,887**	**0,970**	**2,18 ± 0,10**	**0,089**	**0,033**	**14,0 / 8**
Bahia	0,83	0,003	0,93	0,207	0,802	2,44 ± 0,13	< 0,001	0,728	16,4 / 18
São Paulo	1,41	< 0,001	0,88	0,199	0,659	1,79 ± 0,05	< 0,001	0,000	70,2 / 78
Rio de Janeiro	1,42	0,045	1,04	0,540	0,900	2,12 ± 0,22	0,580	0,412	31,0 / 28
Minas Gerais	1,07	0,188	0,87	< 0,001	0,641	2,08 ± 0,06	0,158	0,227	31,2 / 34
Paraná	1,12	0,124	0,84	< 0,001	0,547	2,05 ± 0,08	0,539	0,663	17,7 / 22
Santa Catarina	1,22	0,029	0,79	< 0,001	0,391	1,95 ± 0,08	0,553	0,380	14,8 / 14
Rio Grande do Sul	1,24	0,002	0,75	< 0,001	0,281	1,73 ± 0,04	< 0,001	0,012	27,4 / 19

Fonte: elaboração própria com dados do IBGE. Os p se referem ao teste $q = 1$ com o erro padrão usual da regressão ou com o de Gabaix e Ibragimov (GI). A última coluna compara o número de municípios com mais de 100 mil habitantes previsto pela lei de potência ajustada com o observado.

4. Limitações

A unidade de análise é o município, que inclui áreas rurais e não coincide com a mancha urbana. Fortaleza, Caucaia e Maracanaú formam uma única aglomeração, e tratá-las separadamente aumenta a primazia aparente da capital; os arranjos populacionais do IBGE seriam uma unidade mais adequada. O estudo usa só o Censo de 2022, o que não permite saber se a concentração aumentou ou diminuiu nem testar diretamente o crescimento proporcional. A escolha de $x_{\min}$ pelo critério de Kolmogorov-Smirnov é objetiva, mas outras escolhas mudam α; com 20 municípios, ou com os 26 da cauda do Rio de Janeiro, os testes têm pouco poder. Os oito estados também não formam uma amostra aleatória: faltam as regiões Norte e Centro-Oeste, e os resultados não devem ser generalizados para o país. Por fim, uma distribuição pode parecer lei de potência sem sê-lo: a distribuição log-normal também é compatível com crescimento proporcional (EECKHOUT, 2004) e não foi testada aqui. Trabalhos futuros podem comparar os censos de 2000, 2010 e 2022, usar arranjos populacionais e aplicar o teste da razão de verossimilhança entre lei de potência e log-normal proposto por Clauset, Shalizi e Newman (2009).

5. Conclusão

A hierarquia populacional do Ceará é compatível com a inclinação da Lei de Zipf, mas não com a sua forma. Pela regressão, q = 0,90 para os 184 municípios e 0,99 para os 20 maiores; pela máxima verossimilhança, α = 2,18 ± 0,10 na cauda acima de 15 mil habitantes, valores compatíveis com $q = 1$ e $\alpha = 2$. O teste de aderência, no entanto, rejeita uma lei de potência única (p = 0,03), porque Fortaleza concentra 27,6% da população estadual e há apenas 8 municípios com mais de 100 mil habitantes, onde o modelo prevê 14. Entre os oito estados comparados, o Ceará tem a segunda maior participação da maior cidade e a terceira maior razão entre os dois primeiros municípios, e é o único em que o expoente é compatível com Zipf, mas a lei de potência é rejeitada. A principal lição de método é a de Newman (2005): o R^2 alto de uma reta em escala log-log não prova a lei, o erro padrão da regressão subestima a incerteza, e a mudança de método basta para inverter a conclusão sobre quatro estados. A Lei de Zipf é útil como referência para comparar redes urbanas, desde que o expoente seja estimado com o método adequado e lido junto com medidas de primazia.

Referências

CLAUSET, A.; SHALIZI, C. R.; NEWMAN, M. E. J. Power-law distributions in empirical data. **SIAM Review**, v. 51, n. 4, p. 661-703, 2009. https://doi.org/10.1137/070710111.

EECKHOUT, J. Gibrat's law for (all) cities. **American Economic Review**, v. 94, n. 5, p. 1429-1451, 2004. https://doi.org/10.1257/0002828043052303.

GABAIX, X. Zipf's law for cities: an explanation. **The Quarterly Journal of Economics**, v. 114, n. 3, p. 739-767, 1999. https://doi.org/10.1162/003355399556133.

GABAIX, X.; IBRAGIMOV, R. Rank – 1/2: a simple way to improve the OLS estimation of tail exponents. **Journal of Business & Economic Statistics**, v. 29, n. 1, p. 24-39, 2011. https://doi.org/10.1198/jbes.2009.06157.

IBGE. **Censo Demográfico 2022: população residente, variação absoluta e taxa de crescimento geométrico**. SIDRA, tabela 4709, 2023. Disponível em: https://sidra.ibge.gov.br/tabela/4709. Acesso em: 29 out. 2026.

NEWMAN, M. E. J. Power laws, Pareto distributions and Zipf's law. **Contemporary Physics**, v. 46, n. 5, p. 323-351, 2005. https://doi.org/10.1080/00107510500052444.

SIMON, H. A. On a class of skew distribution functions. **Biometrika**, v. 42, n. 3/4, p. 425-440, 1955. https://doi.org/10.2307/2333389.

SOO, K. T. Zipf's law for cities: a cross-country investigation. **Regional Science and Urban Economics**, v. 35, n. 3, p. 239-263, 2005. https://doi.org/10.1016/j.regsciurbeco.2004.04.004.

ZIPF, G. K. **Human behavior and the principle of least effort**. Cambridge: Addison-Wesley, 1949.